


LAPORAN MACHINE LEARNING PERTEMUAN 4

Nama : Bagus Arya Sena
NIM : 231011402751
Kelas : 05TPLE017
Prodi : Teknik Informatika

Langkah 1 — Buat Dataset CSV



```
kelulusan_mahasiswa.csv
1  IPK,Jumlah_Absensi,Waktu_Belajar_Jam,Lulus
2  3.8,3,10,1
3  2.5,8,5,0
4  3.4,4,7,1
5  2.1,12,2,0
6  3.9,2,12,1
7  2.8,6,4,0
8  3.2,5,8,1
9  2.7,7,3,0
10 3.6,4,9,1
11 2.3,9,4,0
```

Dataset dibuat secara manual berisi data mahasiswa dengan atribut:

- IPK, Jumlah_Absensi, Waktu_Belajar_Jam, dan Lulus.
- Data disimpan dengan nama kelulusan_mahasiswa.csv menggunakan tanda koma (,) sebagai pemisah.

Langkah 2 — Collection

Dataset dibaca menggunakan Pandas:

```
> ~
import pandas as pd
df = pd.read_csv("kelulusan_mahasiswa.csv")
print(df.info())
print(df.head())

[13]

... <class 'pandas.core.frame.DataFrame'>
RangeIndex: 10 entries, 0 to 9
Data columns (total 4 columns):
#   Column                Non-Null Count  Dtype
---  -
0   IPK                    10 non-null    float64
1   Jumlah_Absensi         10 non-null    int64
2   Waktu_Belajar_Jam      10 non-null    int64
3   Lulus                   10 non-null    int64
dtypes: float64(1), int64(3)
memory usage: 448.0 bytes
None
   IPK  Jumlah_Absensi  Waktu_Belajar_Jam  Lulus
0  3.8                3                 10      1
1  2.5                8                  5      0
2  3.4                4                  7      1
3  2.1               12                  2      0
4  3.9                2                 12      1
```

Data berhasil dimuat, berisi 4 kolom numerik tanpa tipe data yang salah.

Langkah 3 — Cleaning


```
> ~
print(df.isnull().sum())
df = df.drop_duplicates()

import seaborn as sns
sns.boxplot(x=df['IPK'])

[14]

... IPK      0
    Jumlah_Absensi  0
    Waktu_Belajar_Jam  0
    Lulus      0
    dtype: int64

... <Axes: xlabel='IPK'>
```




Langkah pembersihan meliputi:




- Mengecek missing value → tidak ditemukan.
- Menghapus duplikat data (jika ada).
- Mengecek outlier menggunakan boxplot pada kolom IPK.

Catatan:

Data bersih dan siap dianalisis, tidak ada nilai kosong maupun duplikat.

Langkah 4 — Exploratory Data Analysis (EDA)





Analisis meliputi:

- Statistik deskriptif (df.describe())

- Histogram distribusi IPK
- Scatterplot hubungan IPK dan Waktu Belajar terhadap Kelulusan
- Heatmap korelasi antar variabel

Catatan:

Ditemukan korelasi positif antara IPK dan waktu belajar terhadap kelulusan, serta korelasi negatif antara jumlah absensi dengan kelulusan.

Langkah 5 — Feature Engineering

```
df['Rasio_Absensi'] = df['Jumlah_Absensi'] / 14
df['IPK_x_Study'] = df['IPK'] * df['Waktu_Belajar_Jam']
df.to_csv("processed_kelulusan.csv", index=False)
```

Dibuat dua fitur turunan baru:

- `df['Rasio_Absensi'] = df['Jumlah_Absensi'] / 14`
- `df['IPK_x_Study'] = df['IPK'] * df['Waktu_Belajar_Jam']`
- Data baru disimpan ke `processed_kelulusan.csv`.

Catatan:

Fitur tambahan membantu meningkatkan representasi data untuk model.

Langkah 6 — Splitting Dataset

```
from sklearn.model_selection import train_test_split

X = df.drop('Lulus', axis=1)
y = df['Lulus']

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, stratify=y, random_state=42)

print("Train set size:", X_train.shape)
print("Test set size:", X_test.shape)

# Cek proporsi kelas di tiap subset
print("Proporsi kelas di train:")
print(y_train.value_counts(normalize=True))
print("Proporsi kelas di test:")
print(y_test.value_counts(normalize=True))
```

Train set size: (8, 5)
Test set size: (2, 5)
Proporsi kelas di train:
Lulus
1 0.5
0 0.5
Name: proportion, dtype: float64
Proporsi kelas di test:
Lulus
0 0.5
1 0.5
Name: proportion, dtype: float64

Dataset dibagi menjadi:

- Train: 70%
- Validation: 15%
- Test: 15%
- Menggunakan stratified split agar proporsi label Lulus tetap seimbang.

Catatan:

Data terbagi dengan baik, siap untuk tahap pemodelan pada pertemuan berikutnya.

Hasil Akhir :

- File processed_kelulusan.csv berisi data bersih + fitur baru
- Visualisasi EDA lengkap
- Dataset terbagi menjadi Train, Validation, dan Test